

基於改進型 Faster R-CNN 之胸腔 X 光 多重病灶自動偵測系統

第一部分：緒論（Introduction）

1.1 Background（研究背景）

胸腔 X 光（Chest X-ray, CXR）是目前臨床上最普及、經濟且快速的醫學影像檢查工具，廣泛應用於肺炎、肺結核、心臟肥大及肺部腫瘤等心肺疾病的初步篩檢與診斷。根據世界衛生組織（WHO）統計，呼吸道疾病是全球主要的死因之一，早期發現與治療對於提升存活率至關重要。

然而，X 光影像的判讀高度依賴放射科醫師的專業經驗與專注力。隨著醫療需求增加，影像數據量呈爆炸性成長，醫師面臨繁重的工作負荷，長時間判讀容易產生視覺疲勞，進而導致漏判或誤判的風險。因此，近年來結合深度學習（Deep Learning）技術的電腦輔助診斷（Computer-Aided Diagnosis, CAD）系統成為研究熱點，旨在協助醫師快速標記異常區域，提升診斷效率與準確性。

1.2 Motivation（研究動機）

儘管深度學習在自然影像（Natural Images）的物件偵測任務上已取得顯著成果，但直接應用於醫學影像仍存在局限性。現有的自動化篩檢系統多著重於單一疾病的分類（Classification），例如僅判斷是否患有肺炎，卻無法精確指出病灶的具體位置（Location）與範圍。這對於臨床醫師而言，參考價值有限，因為「病灶在哪裡」往往比「有沒有病」更能輔助後續的切片或治療決策。

此外，胸腔疾病往往呈現多樣化且可能同時發生（Multi-label），例如病患可能同時患有心臟肥大與肺浸潤。因此，本研究希望能開發一套基於深度學習的物件偵測模型，不僅能進行多標籤疾病分類，更能精準框選出病灶區域（Bounding Box），提供具備可解釋性的視覺化輔助資訊。

1.3 Research Aims（研究目標）

本研究旨在建立一個高效能的胸腔 X 光病灶偵測系統，具體目標如下：

1. **建構自動化偵測模型：**實作並訓練基於 Faster R-CNN 架構的物件偵測模型，以自動識別並定位胸腔 X 光中的異常病灶。
2. **多疾病類別識別：**模型需具備處理多標籤（Multi-label）任務的能力，能同時偵測包含心臟肥大、肺浸潤、脊椎側彎等 7 種常見胸腔疾病。
3. **克服醫學影像特性挑戰：**針對醫學影像資料稀缺與類別不平衡等問題，設計適當的資料前處理與訓練策略，以提升模型的泛化能力與穩健性。

1.4 Challenges（挑戰與子問題）

為達成上述目標，本研究在技術實作上面臨以下四大挑戰。這些挑戰將主導後續第三章的建模策略與實驗設計：

- **挑戰一：高品質標註資料取得不易與小樣本問題（Data Scarcity）**
 - **問題描述：**相較於自然影像（如 ImageNet、COCO）擁有百萬級別的數據，醫學影像需由專業醫師進行標註，成本極高且取得困難。本研究可用的訓練資料量相對稀少，直接從頭訓練（Train from scratch）深層網路極易導致過度擬合（Overfitting）。
- **挑戰二：類別不平衡（Class Imbalance）**
 - **問題描述：**在醫學篩檢資料中，正常樣本（Normal）和特定疾病（如肺部結節或特定病變）的樣本量有所不同。例如本資料集中，最高比例的疾病有 15%，最低則只有 6%。若未經處理，模型傾向於預測多數類別，導致對少數關鍵疾病的敏感度（Sensitivity）大幅下降。
- **挑戰三：病灶尺度變異大與特徵模糊（Scale Variation & Low Contrast）**
 - **問題描述：**不同疾病在 X 光片上的呈現大小差異巨大。例如「心臟肥大」佔據影像大面積，而「肺部結節」或「主動脈鈣化」可能僅佔極小像素區域。此外，X 光為灰階疊加影像，軟組織與病灶的對比度低（Low Contrast），邊界模糊不清，增加了特徵提取的難度。
- **挑戰四：特殊的影像格式與前處理需求（Domain-Specific Format）**

- **問題描述：** 原始醫學影像通常為 DICOM 格式，包含高動態範圍的像素數值（12-bit 或 16-bit），無法直接輸入至僅接受 8-bit RGB 格式的標準卷積神經網路。若直接壓縮數值範圍，可能導致關鍵病徵細節流失。

1.5 Problem Definition（問題定義）

本研究將胸腔疾病診斷定義為一個**多標籤物件偵測（Multi-label Object Detection）**問題。

- **輸入（Input）：**
 - 一張單通道或三通道（經轉換後）的胸腔 X 光影像 I ，尺寸為 $H \times W$ 。
 - 影像需先經過強度正規化（Normalization）處理，像素值範圍映射至 $[0,1]$ 。
- **輸出（Output）：**
 - 一組檢測到的邊界框（Bounding Boxes）集合 $B = \{b_1, b_2, \dots, b_k\}$ 。
 - 對於每一個檢測到的框 b_i ，包含以下資訊：
 - **位置座標：** $(x_{\min}, y_{\min}, x_{\max}, y_{\max})$ ，代表病灶在影像中的矩形範圍。
 - **類別標籤（Category Label）：** $c_i \in \{1, 2, \dots, C\}$ ，對應 7 種特定的疾病類別（如 Aortic enlargement, Cardiomegaly 等）。
 - **信心分數（Confidence Score）：** $s_i \in [0,1]$ ，代表模型對於該預測結果的確信程度。

第二部分：資料前處理（Data Preprocessing）

2.1 Data Description（資料描述）

本研究使用之資料集來自多名志願者所拍攝的**胸腔 X 光影像（Chest X-ray）**，影像中標註了多種臨床常見之胸腔相關疾病。資料共涵蓋 **8 種類別**，包含：**normal（無疾病）**、主動脈硬鈣化、主動脈彎曲、肺野浸潤增加、胸椎退化性關節病變、脊椎側彎、肺尖肋膜增厚以及心臟肥大。需注意的是，每位志願者

的影像可能同時具有一種以上疾病標註，因此本資料屬於**多標籤 (multi-label)**性質。

在資料結構方面，所有**訓練資料**存放於 `train/` 資料夾中，並依疾病類別分成不同子資料夾。每一類疾病資料夾下包含兩個子資料夾：

- `image/`：存放原始胸腔 X 光影像（.dcm 格式）
- `mark/`：存放對應之病灶標註影像（.dcm.jpg），由專業醫師進行病徵區域標記

訓練集的整體資訊彙整於 `train.csv` 中，共包含 **451 筆訓練資料**，每一列對應一張影像與其疾病標註，並包含 **7 個欄位**，說明如下：

- **ID**：志願者唯一識別碼，相同 ID 代表同一位受試者
- **category**：疾病種類（8 類）
- **Width、Height**：影像解析度，寬度介於 1536 – 2680 pixels，高度介於 1824 – 2688 pixels
- **Filename**：影像檔案名稱
- **ImagePath**：影像檔案完整路徑
- **MarkPath**：疾病區域 bounding box 標註檔案路徑

此外，**測試資料集**存放於 `test/` 資料夾中，影像位於 `test/image/`，格式同為 .dcm(一共 113 張)，其對應資訊則記錄於 `test.csv` 檔案中。

2.2 Data Understanding（資料理解）

執行：`preprocess1_EDA.py`

為了深入理解資料特性與分佈情形，本研究針對訓練資料進行探索性資料分析（Exploratory Data Analysis, EDA）。分析內容包含：


1. **疾病類別分佈 (Label Distribution)**，用以檢視是否存在類別不平衡問題
2. **影像解析度分佈**，確認影像尺寸的變化範圍與一致性
3. **透過視覺化圖表（如圓餅圖）**，直觀呈現資料組成與比例

表格 1. 疾病類別分佈


疾病類別	數量
Normal	80

aortic_atherosclerosis_calcification	71
lung_field_infiltration	68
degenerative_joint_disease_of_the_thoracic_spine	60
scoliosis	58
aortic_curvature	52
cardiac_hypertrophy	33
intercostal_pleural_thickening	29

圖表 1. 疾病分布圓餅圖



圖表 2. 影像解析度分析



此分析有助於後續模型設計與訓練策略（例如類別不平衡處理或資料前處理方式）的合理規劃。

2.3 Data Preparation（資料準備）

任務 1. 檔案命名與編碼處理

由於原始資料(資料夾命名、train.csv 內)的胸腔疾病為中文名稱，對於讀取資料非常不方便，需要先轉為對應的英文名。這部分單純的更改資料夾名稱，以及使用 excel 打開 csv 檔，並且使用取代功能手動更改名稱。以下是對應的更動：

- normal -> normal
- 心臟肥大 -> cardiac_hypertrophy
- 主動脈硬鈣化 -> aortic_atherosclerosis_calcification
- 主動脈彎曲 -> aortic_curvature
- 肺尖肋膜增厚 -> intercostal_pleural_thickening
- 肺野浸潤增加 -> lung_field_infiltration
- 胸椎退化性關節病變 -> degenerative_joint_disease_of_the_thoracic_spine
- 脊椎側彎 -> scoliosis

任務 2 由分割遮罩 (Mask) 轉換為邊界框

(Bounding Box) 之方法說明

執行：preprocess2_bbox.py

在本研究中，為了將語意分割標註 (segmentation mask) 轉換為物件偵測所需的邊界框 (bounding box)，我們設計並使用 mask_to_bbox() 函數。此函數的主要功能是：根據二值化的標註遮罩，計算出包含目標物的最小外接矩形座標。

處理流程說明

首先，函數以單張影像對應的二值遮罩作為輸入，其中遮罩中像素值為 1 (或非零) 代表目標區域，0 則代表背景。接著，透過搜尋遮罩中所有非零像素的位置，取得目標物在影像中的實際分布範圍。

在取得這些有效像素座標後，分別對其在水平方向 (x 軸) 與垂直方向 (y 軸) 進行統計，計算：

- 最小 x 值 (xmin)

- 最大 x 值 (xmax)
- 最小 y 值 (ymin)
- 最大 y 值 (ymax)

上述四個值即構成一個能完整包覆目標物的最小邊界框，確保邊界框不包含多餘背景，同時完整涵蓋所有目標像素。

輸出格式與用途

`mask_to_bbox()` 函數最終會輸出一組邊界框座標，通常以 (xmin, ymin, xmax, ymax) 的格式表示。此座標可直接應用於：

- 物件偵測模型（如 YOLO、Faster R-CNN）的標註資料製作
- 將原本的 segmentation 任務轉換為 detection 任務
- 後續影像裁切 (cropping) 或區域分析 (ROI analysis)

方法優點

此方法具有以下優點：

1. **自動化**：可直接由像素級標註產生 bounding box，無需人工標記
2. **精確性高**：邊界框緊密包覆實際目標區域
3. **實作簡單、計算效率高**：僅需基本的陣列運算即可完成

因此，透過 `mask_to_bbox()` 函數，可以有效地將語意分割資料轉換為適用於物件偵測與定位任務的標註格式，提升資料使用的彈性與實務應用價值。

任務 3. X-ray 影像正規化與視覺化 (Image Normalization and Visualization)

執行：`preprocess3_XrayNorm.py` 的區塊 `preprocess3`

由於本研究所使用之胸腔 X-ray 影像為 DICOM 格式，其像素值分布受到醫學影像成像流程與顯示設定影響，並不直接對應於實際可視亮度。因此，若直接將原始像素值輸入深度學習模型，可能導致模型學習到不具臨床意義的強度特

徵，影響疾病偵測效能。為此，本研究依作業說明，對所有 X-ray 影像進行一致的正規化處理，流程包含 **Intensity Log-Transformation** 與 **Saturation-based Linear Stretching** 兩個步驟。

Intensity Log-Transformation

根據 DICOM 檔案中的 metadata，本資料集之胸腔 X-ray 影像具有 **Pixel Intensity Relationship = LOG** 以及 **Photometric Interpretation = MONOCHROME1** 的特性，代表像素值與 X-ray 光子強度呈對數關係，且顯示亮暗方向為反轉。為恢復具有實際意義的影像強度分布，本研究首先進行強度對數轉換。

具體作法如下：

先由 DICOM 檔案中讀取 Window Width (WW)、Window Center (WC) 與 BitsStored，並依下式計算像素值有效範圍的上下界：

$$\bullet \quad i_{max} = \frac{WW+2WC}{2}, \quad i_{min} = \frac{2WC-WW}{2}$$

接著將原始像素值限制於 $[i_{min}, i_{max}]$ 區間內，以避免極端值對後續轉換造成干擾。最後，依照資料集特性對像素值進行對數反轉轉換，其形式如下：

$$z = -\log\left(\frac{1+x}{2^{BitsStored}}\right)$$

此步驟可將經對數編碼且反轉之像素值，轉換回較符合實際組織結構的強度分布。

Saturation-based Linear Stretching


在完成對數轉換後，部分影像中仍可能出現與疾病偵測無關之高亮區域，例如左右胸腔標記 (L/R) 或文字標註，這些區域容易因強度過高而干擾模型學習。因此，本研究進一步採用 **Saturation-based Linear Stretching** 進行對比調整。

具體而言，將經 log-transformation 後的影像以固定上下界($v_{min} = 0, v_{max} = 2.5$)進行線性正規化，使像素值映射至 $[0,1]$ 區間，並將超出範圍的數值截斷。此步驟可有效壓縮過曝區域，同時提升胸腔結構（如肺野、心臟輪廓與骨骼）的對比度，使影像更適合作為深度學習模型的輸入。

正規化結果之視覺化分析

為驗證正規化流程的效果，本研究將原始 DICOM 影像與正規化後影像進行視覺化比較。透過影像顯示，可觀察到正規化後影像之亮暗關係更符合人眼對 X-ray 影像的直觀判讀，且像素值分布集中於[0,1]區間，有助於穩定模型訓練並提升學習效率。

圖表 3. X-ray 影像正規化前後比較



整體而言，上述正規化與視覺化流程確保所有輸入影像在強度尺度與對比上具有一致性，降低因成像與顯示差異所造成的影響，並為後續胸腔疾病偵測模型提供更具代表性的輸入資料。

任務 4.影像資料清理後的儲存（Image Saving after Data Cleaning）

執行：preprocess3_XrayNorm.py 的 區塊 preprocess4

在完成 X-ray 影像正規化與病灶區域標註（Bounding Box）萃取後，本研究進一步將處理完成之影像儲存為標準影像格式，以利後續深度學習模型之訓練與測試。本任務的目標為將原始 DICOM 醫學影像轉換為經正規化處理後的 JPG 影像，並依據資料集用途（訓練集與測試集）進行系統化的儲存與管理。

訓練集影像儲存

對於訓練資料，本研究逐筆讀取資料表（DataFrame）中所記錄之 DICOM 影像路徑，並執行以下處理流程：

1. **影像格式轉換與儲存**

將正規化後的影像以灰階（grayscale）形式儲存為 JPG 格式，並依據影像所屬之病灶類別（category）建立對應的子資料夾，使資料結構符合常見影像分類與偵測模型的訓練需求。

2. **資料夾與流程管理**

系統會自動建立尚未存在的輸出資料夾，並於每處理 50 張影像時顯示進度資訊，以利監控批次處理狀態。

透過上述流程，訓練集影像得以在保留病灶視覺特徵的同時，轉換為適合深度學習模型輸入的標準影像格式。

測試集影像儲存

測試資料之處理流程與訓練集大致相同，差異在於影像的儲存方式：

1. **統一儲存位置**

所有測試影像皆儲存於同一個 test 資料夾中，而不依病灶類別進行分類，以避免在模型推論階段洩漏任何標籤資訊。

2. **影像處理流程一致性**

測試集影像同樣經過 X-ray 正規化與灰階 JPG 儲存，確保訓練與測試資料在影像分布與前處理流程上具有一致性。

3. **命名規則**

影像檔名統一以影像 ID 命名（{Filename}.jpg），方便後續結果比對與模型輸出之追蹤。

任務四之目的與重要性

本任務完成後，原始且體積龐大的 DICOM 醫學影像被轉換為經正規化處理的 JPG 影像，不僅大幅提升資料讀取與訓練效率，也使資料結構更符合主流電腦視覺模型（如 CNN、Object Detection 模型）的輸入格式需求。此外，透過一致化的前處理與儲存規則，可確保訓練集與測試集在資料品質與分布上的一致性，進而提升模型訓練的穩定性與推論結果的可靠性

任務四之補充

執行：執行 preprocess3_XrayNorm.py 的 區塊 4-2

另外更新 train.csv 以及 test.csv，將新的經過正規化的圖片路徑加入新的欄位中，命名為['NormImagePath']，並且將 train.csv 的 category 類別名稱轉為 0~7 的數字 ID['class_id']，方便日後深度學習使用。

任務 5. 資料分割方法（Training / Validation Split）

執行：preprocess5_TrainValSplit.py

在醫學影像分析任務中，若同一位病人的影像同時出現在訓練集與驗證集中，模型可能間接學習到病人特有的影像特徵，導致評估結果過度樂觀，形成嚴重的 **data leakage** 問題。因此，本研究在資料分割階段採用**以病人 ID 為單位（patient-wise split）**的策略，以確保模型評估的公平性與泛化能力。

病人層級的多標籤分層分割

由於每位病人可能同時具有多種胸腔疾病（multi-label setting），本研究在資料分割時同時考量病人層級與疾病類別分布。具體作法如下：首先，以病人 ID 為單位彙整該病人所對應的所有疾病標籤，形成每位病人的多標籤集合。接著，透過 multi-label one-hot encoding 將每位病人的疾病資訊轉換為向量表示。

在此基礎上，使用 **iterative stratified splitting** 方法對病人 ID 進行分層抽樣，將約 80% 的病人分配至訓練集，其餘 20% 分配至驗證集。此方法能在病人層級

進行分割的同時，盡量維持各疾病類別在訓練集與驗證集中的比例一致，避免類別分布失衡對模型訓練與評估造成偏差。

完成病人層級分割後，再依據病人 ID 將原始影像資料對應回訓練集與驗證集，確保同一位病人的所有影像資料只會出現在其中一個資料集，從根本上杜絕資料洩漏的可能性。


分割結果驗證與視覺化

為確保資料分割的正確性與合理性，本研究進一步進行以下驗證與分析：

- 1. **病人 ID 驗證：**檢查訓練集與驗證集中的病人 ID 是否存在交集，確認不存在任何病人同時出現在兩個資料集中。
- 2. **類別分布分析：**統計並比較訓練集與驗證集中各疾病類別的樣本數量，並以長條圖視覺化兩者的分布情形。
- 3. **比例統計表：**列出各疾病類別在訓練集與驗證集中的樣本數與百分比，以量化分割後的資料平衡程度。

透過上述病人層級、多標籤分層的資料分割策略與完整的驗證流程，本研究能在避免 data leakage 的前提下，建立具有良好泛化能力的胸腔 X-ray 疾病偵測模型，確保後續模型訓練與效能評估結果具備可信度與臨床參考價值。

圖表 4. 訓練以及驗證資料切割比例



表格 2. 各項疾病於驗證集占比

Category	Val %
----------	-------

0	aortic_atherosclerosis_calcification	15.38%
1	aortic_curvature	10.99%
2	cardiac_hypertrophy	7.69%
3	degenerative_joint_disease_of_the_thoracic_spine	13.19%
4	intercostal_pleural_thickening	6.59%
5	lung_field_infiltration	15.38%
6	normal	17.58%
7	scoliosis	13.19%

任務 6. COCO 資料格式建構與驗證

執行：preprocess6_COCO.py

為了能夠使用主流之深度學習目標偵測模型（如 Faster R-CNN、Mask R-CNN、RetinaNet、YOLO 等），本研究將處理完成之胸腔 X-ray 影像與其對應之病灶標註資訊，統一轉換為 COCO（Common Objects in Context）格式。COCO 為目前電腦視覺領域中最廣泛使用的資料標註標準之一，能有效提升模型訓練流程的通用性與可重現性。

COCO 資料結構設計

在 COCO 格式中，資料主要由四個核心區塊組成：info、images、annotations 與 categories。

1. info

用於描述資料集的基本資訊，包括資料集名稱、版本、建立年份與日期等，用以標示資料來源與版本控管。

2. categories

本研究的原始資料包含 8 類胸腔狀態，其中「normal」類別不包含任何病灶位置，因此在 COCO 標註中予以排除。最終僅保留 7 種具備定位資訊的疾病類別，並為每一類別指定唯一的 category_id，以符合 COCO detection 任務的標準設計。

3. images

每張影像皆對應一筆 images 記錄，內容包含影像的唯一識別碼 (id)、檔名 (file_name)、影像寬度 (width) 與高度 (height)。影像 ID 由 0 開始連續遞增，以利後續標註對應。

4. annotations

每一筆病灶標註皆對應一筆 annotations 記錄，僅針對非 normal 的影像建立標註。標註內容包含：

- id：唯一的標註識別碼
- image_id：對應之影像 ID
- category_id：疾病類別 ID
- bbox：以 [xmin, ymin, width, height] 表示的 bounding box
- area：bounding box 面積
- iscrowd：設為 0
- segmentation：空列表（本研究為 bounding box 偵測任務）

其中，bounding box 由前一階段所計算之 (xmin, ymin, xmax, ymax) 轉換而得，確保格式符合 COCO 規範。

訓練集與驗證集標註檔生成

在完成病人層級的資料分割後，本研究分別針對訓練集與驗證集產生對應的 COCO 標註檔：

- annotations_train.json
- annotations_val.json

每個標註檔皆獨立包含其對應資料集的影像與標註資訊，並統計輸出影像數量、標註數量（非 normal）以及各疾病類別的樣本分布，作為資料完整性與平衡性的初步檢查。

COCO 標註格式驗證

為確保所產生之 COCO 標註檔可被後續模型訓練框架正確讀取，本研究進一步實作自動化驗證流程，檢查以下項目：

1. **必要欄位檢查**：確認 info、images、annotations、categories 皆存在。
2. **ID 正確性**：檢查 image_id 是否唯一且連續，annotation_id 是否唯一。

3. **參照一致性**：確認每筆 annotation 中的 image_id 與 category_id 均能在 images 與 categories 中找到對應項目。
4. **Bounding box 合法性**：確認 bbox 格式正確、數值為正，且不超出影像實際尺寸範圍。

經由上述完整的格式建構與驗證流程，可確保資料標註具備結構一致性與正確性，使後續深度學習目標偵測模型之訓練與評估能夠順利進行，並提升研究結果的可靠性與可重現性。

第三部分：建模與實驗設計

3.1 模型架構選擇（Model Architecture）

本研究採用 **Faster R-CNN (ResNet-50 FPN V2)** 作為胸腔 X 光影像病灶偵測之主要模型。Faster R-CNN 屬於兩階段（two-stage）物件偵測架構，首先由區域提議網路（Region Proposal Network, RPN）在共享特徵圖上產生候選區域（Region Proposals），再針對這些區域進行精細的分類與邊界框回歸。相較於單階段偵測器，此架構在抑制背景雜訊與提升定位精度上具有顯著優勢，特別適用於病灶邊界模糊且對準確度要求極高的醫學影像分析。

3.1.1 骨幹網路升級（Backbone with Improved Weights）

有別於傳統實作，本研究選用了 torchvision 提供之 **ResNet-50 FPN V2** 版本作為骨幹網路。V2 版本採用了更現代化的訓練配方（Training Recipes），包含更強的數據增強策略與優化演算法，在 COCO 基準測試上的特徵提取能力優於原始版本（V1）。骨幹網路結合了特徵金字塔網路（FPN），透過自上而下的路徑與橫向連接，融合高層語意資訊與低層空間細節，使模型能有效應對胸腔 X 光中尺度差異巨大的病灶（如微小結節與大範圍浸潤）。

3.1.2 自適應錨框策略（Adaptive Anchor Strategy）

考量通用模型的預設錨框（Anchors）主要針對自然場景設計，無法有效適應胸腔病灶的特殊幾何形狀，本研究針對資料集特性重新設計了 **Anchor Generator**，進行了以下兩項關鍵優化：

1. **尺寸重新定義（Custom Sizes）**：針對 FPN 的五層特徵圖（P2 至 P6），本研究將錨框基礎尺寸設定為（16, 32, 96, 224, 584）。其中包

含極小的 16 與 32 像素以捕捉微小病灶，以及較大的 584 像素以覆蓋心臟肥大或大面積浸潤，確保模型在經過縮放後的特徵圖上仍能匹配真實病灶大小。

2. **長寬比擴充 (Extended Aspect Ratios)**：鑑於部分病灶（如脊椎側彎、肋膜增厚）具有極端的細長幾何特徵，本研究捨棄了傳統的 (0.5, 1.0, 2.0) 設定，改為使用 (0.25, 0.5, 1.0, 2.0, 3.0) 五種比例。特別引入 **0.25 (1:4)** 與 **3.0 (3:1)** 的極端比例，大幅提升了 RPN 對於垂直細長或水平寬扁病灶的覆蓋率與初始召回率 (Recall)。

3.1.3 RPN 與分類器重組 (RPN & Head Re-initialization)

配合上述錨框策略的改變，本研究重構了 RPN Head，使其輸出通道數與新的錨框數量（每位置 5 個 Anchors）相匹配。同時，在候選區域特徵擷取部分採用 **RoI Align** 技術，透過雙線性插值解決量化誤差問題，精確保留病灶的空間資訊。最後，模型的分類器 (FastRCNNPredictor) 亦針對本資料集之 N 種病灶類別進行替換，將輸出維度設定為 $N+1$ （包含背景），以確保模型能正確執行多標籤分類任務。

3.2 資料集設計與資料讀取機制 (Dataset Design)

3.2.1 COCO 格式資料結構

本研究將所有影像與標註資料整理為 COCO (Common Objects in Context) 格式，以確保能與 torchvision 提供之目標偵測模型無縫整合。COCO 標註檔主要包含以下幾個核心欄位：

- **images**：紀錄所有影像之基本資訊，包括影像 ID、檔名、影像寬高等。
- **annotations**：儲存每一個病灶實例之標註資訊，包含 bounding box 座標、所屬類別 ID 與病灶面積。
- **categories**：定義所有病灶類別名稱與其對應之類別 ID（僅包含非 normal 類別）。
- **info**：描述資料集來源、版本與相關說明。

特別需要說明的是，**正常 (Normal) 影像並不包含任何病灶標註**，因此僅出現在 images 欄位中，而不會對應任何 annotations。此設計完全符合 COCO 官方規範，並可使模型在訓練過程中，將該類影像自然視為僅包含背景之樣本，進而學習更穩健的背景判斷能力。

3.2.2 ChestXrayDataset 類別實作

為配合 Faster R-CNN 之訓練流程，本研究實作自訂的 **ChestXrayDataset** 類別，繼承自 `torch.utils.data.Dataset`，負責影像與標註資料之讀取、整理與轉換。

在 `__getitem__` 方法中，每一筆資料會回傳以下兩個項目：

- **image**：由原始 X-ray 影像讀取後轉換為 RGB 格式之影像張量（3 channels），以符合 ResNet-50 骨幹網路之輸入需求。
- **target**：一個 dictionary，完整包含 Faster R-CNN 所需之標註資訊。

target 字典包含以下欄位：

- **boxes**：病灶邊界框座標，格式為 `[x1,y1,x2,y2]`。
- **labels**：對應之疾病類別 ID。
- **image_id**：影像之唯一識別碼。
- **area**：bounding box 面積，用於 COCO 評估指標計算。
- **iscrowd**：是否為群體標註（本研究資料皆設為 0）。

針對 **正常影像（無任何病灶標註）**，Dataset 類別會回傳形狀為 `[0,4]` 的空 bounding box tensor，並搭配對應維度為 0 的 labels、area 與 iscrowd。此設計可確保在模型訓練時不會發生 tensor 維度錯誤，同時使 Faster R-CNN 能正確將該影像視為純背景樣本進行學習。

3.2.3 影像轉換與正規化（Transforms & Normalization）

由於本研究採用 **載入 COCO 預訓練權重的 Faster R-CNN（ResNet-50 backbone）**，模型在預訓練階段所接收的輸入影像皆已經過特定的標準化（Normalization）處理。為避免輸入資料分佈與預訓練模型不一致，造成模型效能下降或訓練不穩定（domain shift），本研究在資料讀取階段明確加入與預訓練模型相同的影像正規化流程。

影像轉換流程如下：

1. **ToTensor**：將原始影像像素值由 `[0,255][0, 255][0,255]` 轉換為 `[0,1][0, 1][0,1]` 的浮點數張量。

2. **Normalize**：使用 ImageNet/COCO 預訓練模型之固定參數進行標準化，均值與標準差分別設定為

$$\text{mean} = [0.485, 0.456, 0.406], \text{std} = [0.229, 0.224, 0.225]$$

此步驟可確保模型在微調（fine-tuning）階段所接收之輸入分佈，與其在 COCO 預訓練階段高度一致，避免模型因輸入尺度差異而出現「水土不服」的問題。

3.2.4 資料增強與類別平衡策略（Data Augmentation & Class Balancing Strategy）

醫學影像資料集普遍存在嚴重的「長尾分佈」與「類別不平衡（Class Imbalance）」問題。不同疾病的樣本數量有所不同，若直接使用均勻採樣進行訓練，模型極易傾向於預測多數類別，導致對稀有病灶的敏感度（Sensitivity）大幅降低。為解決此問題，本研究採取了「權重過採樣」結合「光度增強」的複合策略。

1. 權重隨機採樣（Weighted Random Sampling）

本研究捨棄了標準的隨機抽樣（Shuffle），改採用 PyTorch 之 `WeightedRandomSampler` 進行批次資料的構建。具體實作邏輯如下：

- **權重計算**：首先統計訓練集中每一類別的樣本總數 N_c ，並計算該類別的採樣權重 $W_c = 1/N_c$ 。此設定確保了樣本數越少的類別，擁有越高的基礎權重。
- **樣本賦權**：針對每一張訓練影像，檢查其包含的所有病灶標籤，並取其中「最稀有（權重最高）」的類別權重作為該張影像的最終採樣機率。這確保了即便一張影像同時包含常見與罕見病灶，模型仍會優先基於罕見病灶的需求進行採樣。
- **替換採樣（Sampling with Replacement）**：設定 `replacement=True`，允許同一張稀有類別的影像在一個 Epoch 中被多次抽取，從而人為地平衡各類別在模型訓練過程中的曝光頻率。

2. 線上光度增強（Online Photometric Augmentation）

單純的過採樣容易導致模型對重複出現的稀有樣本產生過擬合（Overfitting），即「死背」特定影像的像素值。為此，本研究在 `get_transform` 流程中引入了即時的光度增強技術：

- **亮度與對比度擾動 (Color Jitter)**：設定 `brightness=0.5` 與 `contrast=0.5`。這意味著影像在每次進入模型訓練前，其亮度與對比度會在 $\pm 50\%$ 的範圍內隨機變化。
- **策略意義**：此舉模擬了臨床環境中因不同 X 光機型、曝光參數或顯影條件所導致的影像變異。更重要的是，當稀有樣本因過採樣而被多次讀取時，模型每次看到的皆是「光影略有不同」的版本。這迫使卷積神經網路 (CNN) 忽略像素強度的絕對值，轉而學習病灶的結構性特徵（如骨骼形狀、邊緣紋理），有效提升了模型的泛化能力。

值得注意的是，本研究刻意排除了幾何增強中的「水平翻轉 (Horizontal Flip)」¹。由於胸腔器官（如心臟、主動脈弓）具有明確的解剖學左右方向性，隨意翻轉可能導致模型學習到錯誤的生理特徵（例如右位心），故僅保留光度增強以維持解剖結構的正確性。

3.3 模型對應挑戰 (Correspondence)

本章節總結上述所提出的模型架構與訓練策略，明確闡述其如何針對第 1.4 節所列之四大挑戰提出具體解決方案。透過針對性的技術設計，本研究旨在克服醫學影像分析中的固有障礙，以實現高準確度與高強健性的病灶偵測。

對應挑戰一：解決小樣本與過度擬合問題 (Addressing Data

Scarcity)

針對醫學影像標註資料稀缺導致的過度擬合風險，本研究採取了以下策略：

- **遷移學習 (Transfer Learning)**：本研究不採用從頭訓練 (Train from scratch) 的方式，而是選用 **ResNet-50 FPN V2** 作為骨幹網路，並載入其在 COCO 資料集上預訓練的權重 (`weights="DEFAULT"`)。這使得模型在初始階段即具備強大的邊緣偵測與紋理提取能力，大幅降低了對本研究訓練樣本數量的需求。
- **線上資料增強 (Online Data Augmentation)**：透過在訓練過程中引入隨機亮度與對比度擾動 (Color Jitter)，每一張訓練影像在不同 Epoch 中皆呈現相異的光影特徵。此舉等同於人為擴充了資料集的多樣性，迫使模型學習病灶的結構本質而非死背特定像素排列，從而提升模型的泛化能力。

對應挑戰二：克服類別不平衡（Addressing Class Imbalance）

針對資料集中常見病灶與稀有病灶（如肋膜增厚）數量懸殊的問題，本研究捨棄了傳統的隨機抽樣，改採 **權重隨機採樣（Weighted Random Sampling）** 機制：

- **頻率平衡機制：** 系統根據各類別樣本數的倒數計算權重，賦予稀有類別極高的採樣機率。在每一個 Batch 的訓練中，稀有病灶出現的頻率被強制提升至與常見病灶相當。此設計直接解決了模型傾向於預測多數類別（Majority Class）的偏差，確保模型對所有病灶類別皆能進行有效的梯度更新與特徵學習。

對應挑戰三：適應尺度變異與模糊特徵（Addressing Scale & Low

Contrast）

這是胸腔 X 光偵測中最艱鉅的挑戰，本研究透過多尺度的架構設計與錨框優化來解決：

- **特徵金字塔網路（FPN）：** 針對「病灶大小差異巨大」的問題，FPN 結構允許模型在 P2（高解析度）層偵測如 16-32 像素的微小结節，同時在 P6（低解析度）層偵測如 500 像素以上的心臟肥大，實現全尺度覆蓋。
- **自定義錨框優化（Custom Anchor Optimization）：** 針對「形狀不規則」的挑戰，本研究捨棄了通用的錨框設定，依據資料集統計結果設計了專屬錨框。特別是引入 0.25（瘦長）與 3.0（寬扁）的長寬比，精準對應了脊椎側彎與肋膜增厚等特殊幾何形狀的病灶，大幅提升了初始候選區域的準確度（IoU）。
- **對比度增強與 RoI Align：** 針對「邊界模糊」與低對比度問題，光度增強策略迫使模型適應不同的對比度條件，學習更魯棒的特徵；而 RoI Align 技術則避免了特徵量化誤差，確保模糊邊界的空間特徵能被精確保留。

對應挑戰四：標準化影像格式處理（Addressing Domain-Specific

Format)

針對原始醫學影像（DICOM）檔案體積龐大、位元深度（Bit-depth）過高且讀取緩慢的問題，本研究實施了 **離線前處理（Offline Preprocessing）** 策略，將資料處理由訓練階段分離，提前完成格式轉換：

- **DICOM 至 JPG 的標準化轉換**：於 2.3 資料準備已完成 DICOM 檔案的標準化任務，並轉存為輕量化的 .jpg 格式。
- **提升 I/O 效率**：透過將檔案轉換為通用的 JPG 格式，不僅解決了 PyTorch 標準影像讀取函式庫（如 PIL, OpenCV）的相容性問題，更大幅縮減了單一檔案的儲存體積。此舉顯著降低了訓練過程中的硬碟 I/O 負載，使 GPU 無需等待龐大的 DICOM 解碼，從而大幅提升了整體訓練速度與迭代效率。

3.4 Interpretability（模型可解釋性）

在醫療影像診斷領域，深度學習模型的「可信度」與「透明度」至關重要。僅憑藉高準確率（Accuracy）或 mAP 指標並不足以完全說服臨床醫師採納 AI 輔助系統，因為深度神經網路常被視為「黑盒子（Black Box）」。若模型依賴錯誤的特徵（例如影像邊緣的文字標籤、金屬夾或特定的儀器偽影）進行分類，即所謂的「捷徑學習（Shortcut Learning）」，將導致嚴重後的誤診風險。

為了解決此問題，本研究引入類別激活映射（Class Activation Mapping, CAM）技術，將模型關注的特徵區域視覺化為熱力圖（Heatmap）。藉由觀察熱力圖的高激活區域是否與病灶的解剖位置吻合，我們可以驗證模型的決策邏輯是否符合醫學常理，並確保模型並非關注於無關的背景雜訊。

本研究針對 Faster R-CNN 架構，採用了以下兩種互補的視覺化方法：

3.4.1 EigenCAM：結構特徵的快速定位

EigenCAM 是一種基於主成分分析（Principal Component Analysis, PCA）的視覺化方法。

- **原理：** 計算卷積特徵圖（Feature Maps）的第一主成分，無需依賴具體的類別梯度。
- **目的：** 能夠快速捕捉模型在影像中關注的「主要結構」與「物體位置」。
- **應用策略：** 本研究利用 EigenCAM 作為初步篩檢工具，確認模型是否能正確區分「肺野區域」與「背景區域」。若 EigenCAM 的熱力圖大量分布於影像角落或黑色背景，即暗示模型可能學到了錯誤的特徵表示。

3.4.2 AblationCAM：類別特徵的因果驗證

為了進一步理解模型如何區分不同的疾病（例如：為何判斷為「心臟肥大」而非「肺浸潤」），本研究採用了更具解釋力的 AblationCAM。

- **原理：** 透過「消融（Ablation）」技術，系統性地移除（設為零）特徵圖中的特定通道，並觀察該通道移除後對預測信心分數（Confidence Score）的影響。若移除某區域特徵導致分數大幅下降，則該區域被視為具備高度重要性。
- **優勢：** 相較於基於梯度的 Grad-CAM，AblationCAM 對於 Faster R-CNN 這類具備複雜 RPN 與 ROI Head 的雙階段檢測器，能提供更細緻且抗雜訊的類別區分能力。
- **實作細節：** 針對 ResNet-50 骨幹網路（Backbone）的最後一層卷積層（Layer 4）進行分析，並使用 FasterRCNNBoxScoreTarget 鎖定模型預測出的 Bounding Box 進行反向歸因。

3.4.3 驗證邏輯與除錯策略

本研究建立了以下標準來評估模型的可解釋性：

1. **病灶重疊率（Lesion Overlap）：** 高激活的紅色熱力圖區域，必須落在模型預測框（Bounding Box）內部或周圍，且需對應到正確的解剖位置（如主動脈鈣化應位於主動脈弓附近）。
2. **背景雜訊排除（Noise Exclusion）：** 熱力圖不應在影像的文字標註、骨骼邊緣以外的背景或醫療儀器管線上產生高反應。
3. **多尺度一致性：** 針對大小不一的病灶（如大面積的心臟肥大與小面積的肺結節），模型應能產生對應尺度的關注區域。

透過上述可視化工具，我們不僅能驗證模型的強健性，更能作為模型除錯（Debugging）的依據。例如，若發現模型對某類疾病的關注點持續偏差，即可針對該類別進行資料增強或調整訓練策略。

3.5 模型訓練策略與超參數設定（Model Training Strategy and Hyperparameters）

基於 Faster R-CNN 架構與前述之資料處理流程，本研究制定了完整的訓練策略與超參數配置。針對醫學影像資料量少且類別極度不平衡的特性，本研究在傳統的隨機梯度下降策略上進行了優化，引入了加權採樣與動態學習率機制，以確保模型能達到最佳收斂效果。

遷移學習與權重初始化（Transfer Learning）

考量到醫學影像標註資料的取得成本高昂，本研究採用遷移學習策略。骨幹網路（Backbone）ResNet-50 FPN V2 載入在 COCO 資料集上預訓練之權重（weights="DEFAULT"）。此策略能讓模型繼承已具備良好邊緣偵測與特徵提取能力的參數，顯著縮短收斂時間，並提升對病灶特徵的捕捉能力。

基於採樣器的資料加載策略（Sampler-based Data Loading）

為了落實第 3.2.4 節所述之類別平衡策略，本研究在訓練集的 DataLoader 配置上做出了關鍵調整：**強制關閉標準的隨機打亂（Shuffle=False）**，並傳入自定義的 WeightedRandomSampler。此設定改變了資料讀取的底層邏輯，使模型不再遍歷固定的資料順序，而是根據計算出的類別權重進行機率性抽取。這確保了在每一個 Batch（大小為 4）中，稀有病灶與常見病灶能以較為均衡的比例進入模型進行梯度更新。

優化器與超參數配置 (Optimizer and Hyperparameters)

本研究選用隨機梯度下降法 (SGD) 作為優化器，關鍵超參數設定如下：

- **基礎學習率 (Learning Rate)**：設定為 0.015。相較於未採樣前的保守設定，由於引入了過採樣機制，模型需要較大的學習率來跳出局部最小值並適應變異較大的 Batch 分佈。
- **動量 (Momentum)**：設定為 0.9，以加速梯度下降過程並抑制震盪。
- **權重衰減 (Weight Decay)**：設定為 0.0005，用於懲罰過大的權重值，提供 L2 正則化效果以降低過度擬合風險。
- **批次大小 (Batch Size)**：設定為 4，以適配 GPU 記憶體限制並維持 Batch Normalization 的統計穩定性。

動態學習率排程 (Dynamic Learning Rate Scheduling)

為進一步提升模型收斂的精確度，本研究捨棄了固定的階梯式衰減 (StepLR)，改用更具適應性的 `ReduceLROnPlateau` 排程器。

- **監控指標**：以驗證集損失 (Validation Loss) 為監控對象 (mode='min')。
- **衰減機制**：設定 `patience=2` 與 `factor=0.3`。意即當驗證損失連續 2 個 Epoch 未能下降時，系統自動判定模型進入停滯期 (Plateau)，並將學習率乘以 0.3 進行衰減。此機制能確保模型在訓練初期快速探索，並在遇到瓶頸時自動縮小步伐以尋找全域最佳解。


5. 驗證、早停與監控機制 (Validation, Early Stopping, and

Monitoring)

- **損失計算**：由於 Faster R-CNN 架構特性，驗證階段需將模型保持在 `train()` 模式但關閉梯度計算 (`torch.no_grad()`) 以取得損失值。
- **早停機制 (Early Stopping)**：設定容忍值 (patience) 為 6。若驗證損失連續 6 個 Epoch 未創下新低，則提前終止訓練，防止模型在訓練後期對訓練集過度擬合。

- **最佳模型保存：**系統僅在驗證損失低於歷史最佳紀錄（best_val_loss）時，才會覆蓋儲存模型權重（best_model.pth）。
- **歷程視覺化：**訓練結束後，系統將自動繪製並儲存 Loss Curve 圖表(如圖 5 所示)，用以分析訓練集與驗證集的收斂趨勢，作為評估模型是否存在 Overfitting 或 Underfitting 的依據。

圖表 5. Loss curve



第四部分：結果與討論（Results & Discussion）

4.1 實驗結果與量化分析（Comprehensive Results）

本研究使用驗證集（Validation Set）對訓練完成的 Faster R-CNN (ResNet-50 FPN V2) 模型進行效能評估。評估指標採用標準 COCO Metrics，並繪製各類別的 Precision-Recall (P-R) 曲線以分析模型在不同病灶上的表現差異。

4.1.1 整體模型效能（Overall Performance）

如表 3 所示，模型在 IoU=0.50 的標準下（AP₅₀），取得了 **0.365** 的平均準確率（mAP）。而在更嚴格的 IoU=0.50:0.95 區間下（AP），mAP 為 **0.183**。

值得注意的是，模型的平均召回率（Average Recall, AR）達到了 **0.487**，顯著高於平均準確率。這表明模型在「偵測到病灶（Finding Lesions）」方面的能力優於「精確定位邊界（Perfect Localization）」。**在醫學輔助診斷的情境中，高召回率（Low False Negative）通常比高準確率更為關鍵**，因為篩檢系統的首要任務是避免漏診，這顯示本模型具備良好的臨床篩檢潛力。


表格 3. 驗證集評估指標摘要

指標	IoU 閾值	目標面積	最大偵測數	數值
Average Precision (AP)	0.50:0.95	all	100	0.183
Average Precision (AP)	0.50	all	100	0.365
Average Precision (AP)	0.75	all	100	0.158
Average Precision (AP)	0.50:0.95	small	100	-1.000
Average Precision (AP)	0.50:0.95	medium	100	-1.000
Average Precision (AP)	0.50:0.95	large	100	0.183
Average Recall (AR)	0.50:0.95	all	1	0.487
Average Recall (AR)	0.50:0.95	all	10	0.487
Average Recall (AR)	0.50:0.95	all	100	0.487
Average Recall (AR)	0.50:0.95	small	100	-1.000
Average Recall (AR)	0.50:0.95	medium	100	-1.000
Average Recall (AR)	0.50:0.95	large	100	0.487

4.1.2 各類別 P-R 曲線分析（Per-Class Analysis）

圖 6 展示了 7 種病灶類別在 IoU=0.5 時的 P-R 曲線與個別 AP 值。根據 AP 分數的高低，可將病灶偵測結果分為三個層次進行探討：

圖表 6. P-R 曲線



1. 高表現群（Structural Lesions）：

- Scoliosis (AP: 0.612) 與 Cardiac Hypertrophy (AP: 0.579) 表現最佳。
- 分析：這兩類病灶具有「全域性形狀特徵（Global Shape Features）」與「高對比度邊界」。脊椎側彎呈現明顯的 S 型骨骼彎曲，心臟肥大則有清晰的心臟輪廓與肺野邊界。本研究針對脊椎設計的 aspect ratio 0.25 (瘦長框)，在此發揮了關鍵作用，使模型能精準捕捉這些具幾何特徵的目標。

2. 中表現群（Calcification & Degeneration）：

- Aortic Curvature (AP: 0.354) 與 Aortic Atherosclerosis Calcification (AP: 0.297) 表現居中。
- 分析：主動脈相關病灶雖然位置相對固定，但鈣化點通常較小且與周圍組織重疊，增加了偵測難度。Degenerative Joint Disease (AP: 0.267) 則因病徵多樣（骨刺、間隙變窄），特徵較難統一。

3. 困難表現群（Textural & Rare Lesions）：


- Lung Field Infiltration (AP: 0.218) 與 Intercostal Pleural Thickening (AP: 0.225) 表現相對較低。
- 分析：

- **浸潤 (Infiltration)**：屬於「質地變化 (Texture)」而非具體物件，邊界極度模糊 (Fuzzy Boundary)，且容易與正常的肺紋理混淆，這是電腦視覺在醫學影像中的典型挑戰。
- **肋膜增厚 (IPT)**：此為本資料集中的「極少數樣本」且特徵微弱。然而，相較於未使用採樣策略前（通常 $AP < 0.05$ ），本研究透過 **Weighted Random Sampler** 強制模型學習，成功將 AP 提升至 **0.225**。P-R 曲線顯示其在低 Recall 區域能維持 1.0 的 Precision，證明模型已具備識別此高難度病灶的初步能力，驗證了類別平衡策略的有效性。

4.2 洞察與錯誤分析 (Insights and Error Analysis)

為了深入探究模型在不同病灶類別上效能差異的根本原因，本研究利用 EigenCAM 技術對 ResNet-50 骨幹網路的最後一層特徵圖進行了視覺化分析。透過將熱力圖 (Saliency Map) 與原始 X 光影像疊加，我們能夠解析模型在進行決策時的關注區域 (Region of Interest, RoI)，並將錯誤歸納為以下三種主要模式。

圖表 7. EigenCAM 熱力圖



1. 幾何結構優勢與形狀偏好 (Geometric Structure & Shape Bias)

分析對象：Scoliosis (AP 0.612), Cardiac Hypertrophy (AP 0.579) EigenCAM 結果顯示，針對這兩類表現最佳的病灶，模型的熱力圖呈現出高度的**「幾何吻合性」**。

- **脊椎側彎 (Scoliosis)：**熱力圖精準地沿著脊椎骨的 S 型彎曲分佈，證明模型成功學習到了全域的形狀特徵 (Global Shape Features)。
- **心臟肥大 (Cardiac Hypertrophy)：**熱區集中於心臟陰影區域，且模型能準確框出擴大的心臟輪廓。 **洞察：**CNN 架構對於具備強烈幾何結構（如線條彎曲、大面積色塊）的物件具有天然的偵測優勢。

2. 特徵錯位與捷徑學習 (Feature Misalignment & Shortcut Learning)

分析對象：Intercostal Pleural Thickening (AP 0.225) 儘管透過 Weighted Random Sampler 解決了樣本數不足的問題，使 AP 從趨近於 0 提升至 0.225，但 EigenCAM 揭露了模型學習上的潛在隱憂。

- **視覺化證據：**在偵測肋膜增厚 (IPT) 時，EigenCAM 的熱力圖高頻率地點亮了**「脊椎」**區域，而非兩側的肋骨邊緣。
- **錯誤原因：**這是一種典型的**「捷徑學習 (Shortcut Learning)」**現象。由於肋膜增厚的邊緣特徵極為微弱 (Low Contrast)，模型發現訓練資料中許多患有 IPT 的病人同時伴隨特定的脊椎特徵（或因拍攝姿勢導致），因此模型選擇了學習較容易識別的「脊椎特徵」來推斷 IPT，而非學習真正的病灶紋理。這解釋了為何其 AP 難以進一步突破，且容易與脊椎側彎產生混淆。

3. 紋理模糊與邊界不確定性 (Texture Ambiguity & Boundary

Uncertainty)

分析對象：Lung Field Infiltration (AP 0.218) 肺野浸潤是本研究中表現最差的類別之一，其錯誤模式主要源於「物件定義」的本質衝突。


- **視覺化證據**：熱力圖顯示模型對此類別的關注點非常發散，常聚焦於心臟周圍或隨機分佈於肺野，且預測框（Bounding Box）往往呈現覆蓋大半個肺部的「巨大框」。
- **錯誤原因**：浸潤（Infiltration）在本質上屬於**「紋理（Texture）」而非具體的「物件（Object）」**。它沒有明確的邊界（Hard Boundary），而是呈現雲霧狀的漸層。Faster R-CNN 作為物件偵測器，強烈依賴明確的邊緣來進行邊界框回歸（Box Regression）。當面對邊界模糊的浸潤時，模型傾向於給出信心分數較低且範圍過大的預測框，導致 IoU 計算時難以達到 0.5 的閾值，產生大量的偽陽性（False Positives）。

4. 類別間的語意重疊（Inter-class Semantic Overlap）

分析對象：Aortic Curvature vs. Calcification EigenCAM 顯示這兩類病灶的熱力圖高度重疊，皆集中於縱膈腔的主動脈弓位置。這表明模型已成功定位了解剖結構，但難以在低解析度的特徵圖上區分「形狀彎曲」與「鈣化點」的細微紋理差異。這導致兩者在分類上容易互相干擾，限制了 AP 的上限。

另一方面也有畫出 AblationCAM 的熱力圖，但由於差異不大就以 EigenCAM 為主要的分析對象。

圖表 8. Eigen V.S. Ablation 範例



4.3 結論 (Conclusion)

本研究旨在開發一套適用於胸腔 X 光的高效能自動化病灶偵測系統。經由完整的模型建構、訓練策略優化以及實驗驗證，本研究已成功達成第 1.3 節所設定之三大研究目標，具體總結如下：

1. 自動化偵測模型之成功建構 (Achievement of Automated Detection)

針對目標一，本研究成功實作並訓練了基於 **Faster R-CNN (ResNet-50 FPN V2)** 架構的物件偵測模型。實驗結果顯示，該模型在驗證集上達到了 **0.365 的 mAP (IoU=0.5)** 與 **0.487 的 Average Recall (AR)**。這證實了所提出的架構具備從複雜的 X 光背景中自動識別異常區域並框選病灶位置的能力，且較高的召回率顯示其作為臨床輔助篩檢工具的潛力，能有效降低漏診風險。

2. 多疾病類別識別之驗證 (Validation of Multi-label Recognition)

針對目標二，模型展現了同時處理 **7 種相異病灶** 的多標籤偵測能力。P-R 曲線與 EigenCAM 分析顯示，模型不僅能精準識別具備明顯幾何特徵的病灶（如脊椎側彎 AP 達 0.612、心臟肥大 AP 達 0.579），亦具備偵測微細特徵病灶（如主動脈鈣化）的能力。儘管在紋理模糊的類別（如肺浸潤）上仍有改進空間，但整體而言，單一模型已成功整合了多種胸腔疾病的診斷邏輯，實現了多目標同步偵測的任務需求。

3. 醫學影像特有挑戰之克服 (Overcoming Domain-Specific

Challenges)

針對目標三，本研究透過一系列針對性的技術策略，有效解決了醫學影像的固有難題：

- **克服類別不平衡**：透過引入 **Weighted Random Sampler**，本研究成功讓極度稀缺的「肋膜增厚 (IPT)」類別之 AP 從趨近於 0 提升至 0.225，證明了頻率平衡策略能有效避免模型偏向多數類別。
- **適應尺度與形狀變異**：針對 X 光病灶形狀不規則的特性，本研究設計的 **自定義錨框 (Custom Anchors)**，特別是 **0.25 (瘦長)** 與 **3.0 (寬扁)** 的長寬比設定，顯著提升了對脊椎與肋膜病灶的覆蓋率。
- **解決資料稀缺**：結合 **ResNet-50 V2 的遷移學習** 與 **線上光度增強 (Photometric Augmentation)**，模型在有限的訓練樣本下仍展現了良好的收斂性，未出現嚴重的過度擬合現象。

綜上所述，本研究不僅建立了一個運作良好的胸腔 X 光偵測系統，更提出了一套整合「特徵工程 (Anchor Design)」與「採樣策略 (Sampling Strategy)」的完整解決方案，為後續醫學影像深度學習研究提供了具參考價值的技術路徑。

4.4 研究限制與未來展望 (Limitations and Future

Work)

儘管本研究透過架構優化與採樣策略，成功在多數病灶上取得了良好的偵測成果，但基於實驗結果與 EigenCAM 的深度分析，目前的方法仍存在以下局限性，尚待未來研究進一步克服。

1. 對「非物件」病灶的偵測極限 (Limitation on Non-object Lesions)

Faster R-CNN 本質上是為具有明確邊界的「剛性物件 (Rigid Objects)」所設計的偵測器。本研究發現，針對 **肺野浸潤 (Lung Field Infiltration)** 這類呈現雲霧狀、邊界模糊且屬於「紋理變化 (Texture Variation)」的病灶，模型的偵測能

力顯著受限（AP 僅 0.218）。模型傾向於預測覆蓋大範圍的候選框以試圖包住病灶，導致定位精確度不足與偽陽性偏高。這顯示單純的物件偵測架構可能不足以完美處理所有類型的醫學異常。

2. 捷徑學習導致的特徵偏差（Bias from Shortcut Learning）

透過 EigenCAM 分析，我們觀察到模型在偵測 **肋膜增厚（Intercostal Pleural Thickening）** 時，存在依賴「脊椎特徵」而非「肋骨邊緣特徵」的捷徑學習現象。這意味著模型雖然在訓練集上能透過相關性（Correlation）抓到標籤，但在面對脊椎正常但患有肋膜病變的測試樣本時，可能會失效。此現象反映了在極小樣本與類別不平衡的條件下，模型容易收斂至次佳解（Sub-optimal Solution）。

3. 類別間的細微特徵混淆（Inter-class Confusion）

在主動脈相關病灶（彎曲與鈣化）的識別上，模型雖然能準確定位解剖位置，但難以區分兩者在紋理上的細微差異。這顯示在輸入影像解析度受限（經過 Resize）的情況下，細微的鈣化點特徵可能在卷積過程中被平滑化，導致分類器難以做出高信心的區別。

未來改進方向（Future Directions）

針對上述限制，本研究提出以下改進方向：

- **引入語意分割輔助（Semantic Segmentation Aid）**：未來可採用 **Mask R-CNN** 或 **Multi-task Learning** 架構，增加一個分割分支（Segmentation Branch）。利用像素級別的監督信號（Pixel-level Supervision），強迫模型學習病灶的精確輪廓與紋理，特別是針對浸潤這類邊界模糊的病灶，分割任務通常能提供比邊界框更豐富的特徵資訊。
- **應用進階資料增強（Advanced Data Augmentation）**：為打破捷徑學習（如脊椎與肋膜的關聯），可引入 **CutMix** 或 **Mosaic** 等增強技術，強制模型在缺乏完整上下文（Context）的情況下，仍需專注於病灶本身的局部紋理特徵。

- **利用大規模醫學預訓練 (Domain-Specific Pre-training)：** 目前模型使用的是自然影像 (COCO) 的預訓練權重。未來可嘗試使用大規模醫學公開資料集 (如 ChestX-ray14 或 MIMIC-CXR) 進行 **Domain Adaptation** 預訓練，讓骨幹網路在微調前即具備對 X 光紋理的基礎理解，預期能進一步提升特徵提取的有效性。